



Tarea 2 Física Computacional

Enzo Ocaranza.

¹*Departamento de Física, Universidad Técnica Federico Santa María, San Joaquín, Chile*

Problema 1: Inteligencia artificial para problemas inversos

a) Conceptos fundamentales de Inteligencia Artificial para problemas inversos

1. Problema Directo vs. Problema Inverso

- **El Problema Directo:** Es el camino tradicional. Si conocemos la masa, el roce γ y la constante del resorte k , simplemente resolvemos la ecuación diferencial $m\ddot{x} + \gamma\dot{x} + kx = 0$ y vemos cómo se mueve la partícula a lo largo del tiempo para obtener $x(t)$. Es un problema bien definido porque sabemos que la solución existe y es única.
- **El Problema Inverso:** Aquí vamos en reversa. Solo vemos la curva de cómo oscila la masa y, a partir de esos datos, queremos adivinar cuánto roce hay (γ) y cual es la constante del resorte (k). Esto es extremadamente difícil por dos grandes razones:
 1. **La matemática:** γ y k están escondidos dentro de exponenciales y cosenos en la solución analítica. Tratar de despejarlos a mano a partir de un montón de puntos discretos es prácticamente imposible.
 2. **El ruido:** En el mundo real, las mediciones siempre tienen ruido. Esto hace que resortes distintos con roces distintos puedan producir curvas que visualmente se ven casi idénticas, lo que nos quita esa respuesta única y vuelve inestable el problema.

2. Aprendizaje Supervisado y la necesidad de Etiquetas

El **aprendizaje supervisado** es como enseñarle a alguien usando una pauta. Le mostramos al modelo muchos ejemplos de señales temporales (la entrada) junto con los parámetros γ y k reales que las generaron (las etiquetas).

¿Necesitamos conocer estas etiquetas siempre? Depende totalmente de la etapa del proceso:

- **En el Entrenamiento (obligatorio):** Aquí el modelo necesita las etiquetas desesperadamente. Las usa para comparar lo que intentó predecir con la realidad, darse cuenta de su propio error y ajustar sus pesos internos para mejorar.
- **En la Inferencia o Producción:** Una vez que el modelo ya aprendió a hacer el camino inverso, le podemos pasar una señal totalmente nueva, y la red será capaz de deducir γ y k por su cuenta.

3. Conjuntos de Entrenamiento (*Train*) y Validación (*Test*)

Separar nuestros datos en dos grupos es completamente necesario para evitar el **sobreajuste** (*overfitting*).



- **Conjunto de Entrenamiento (*Train*):** Es un grupo grande de datos (por lo general el 80 %) que se usa como material de estudio para que el algoritmo aprenda y se moldee.
- **Conjunto de Prueba (*Test*):** Es el 20 % restante y se usa como un examen final. Si evaluáramos al modelo con las mismas señales que usó para estudiar, la red podría simplemente aprenderse los datos de memoria (incluyendo el ruido) en vez de entender el problema en sí. Al probarlo con datos nuevos que jamás ha visto, comprobamos si de verdad aprendió a generalizar.

4. Función de Pérdida (Error Cuadrático Medio - MSE)

La **función de pérdida** es la forma matemática que tiene el modelo para medir qué tan equivocado está. Usamos específicamente el Error Cuadrático Medio:

$$MSE = \frac{1}{N} \sum_{i=1}^N \left((\gamma_i - \hat{\gamma}_i)^2 + (k_i - \hat{k}_i)^2 \right)$$

por tres grandes ventajas prácticas:

1. **Castiga los errores graves:** Al elevar la diferencia al cuadrado, equivocarse por mucho castiga más que equivocarse por poco. Esto obliga al modelo a corregir rápidamente sus predicciones.
2. **Es suave matemáticamente:** La función cuadrática dibuja una curva suave y sin saltos bruscos (es derivable en todo punto). Esto es vital para que los algoritmos puedan calcular las derivadas y obtener el error mínimo.
3. **Hace sentido estadístico:** Si asumimos que el ruido experimental de nuestras mediciones sigue una clásica campana de Gauss, minimizar este error cuadrático es matemáticamente equivalente a encontrar la predicción más probable.

b) Generación de Datos Sintéticos y Análisis Físico




Figura 1: Visualización de cuatro osciladores extremos generados sintéticamente. La línea punteada negra es la señal pura (analítica) y la línea roja representa la medición con ruido experimental añadido ($\sigma = 0,02$).

Al observar estos cuatro regímenes en el gráfico, podemos concluir lo siguiente sobre el comportamiento del sistema:

- **Efecto de γ (El decaimiento):** El parámetro γ representa el roce y se encarga de reducir la amplitud de la oscilación a lo largo del tiempo. En los gráficos de arriba (donde γ es bajito, cerca de 0,05), el sistema casi no pierde energía y sigue oscilando alegremente hasta el segundo 10. En los gráficos de abajo (donde γ está cerca de 1,0), el roce es tan pronunciado que la oscilación decae rápidamente antes de llegar a la mitad del tiempo.
- **Efecto de k (La frecuencia):** El parámetro k es la rigidez del resorte y domina directamente la rapidez con la que la partícula oscila. Si miramos la columna izquierda (un resorte con $k \approx 1,0$), las ondas son largas y 'tranquilas'. En la columna derecha (un resorte con $k \approx 5,0$), el resorte se comprime y estira muy rápido, empaquetando muchas más oscilaciones en los mismos 10 segundos.

El problema del ruido al final de la medición: El gráfico también nos muestra visualmente por qué el problema inverso es tan complicado. Al principio (cerca de $t = 0$), la oscilación es tan grande que el ruido experimental casi ni se nota. Sin embargo, a medida que la señal se frena (especialmente en los casos con mucho roce), la onda se vuelve tan pequeña que termina siendo tragada por completo por el ruido rojo. Desde ese momento, el resorte sigue ahí, pero la información se pierde.



c) Entrenamiento y Evaluación de Modelos

Para resolver el problema inverso, tomamos nuestras 3000 señales ruidosas y las dividimos: un 80 % (2400 señales) se usó exclusivamente para entrenar a los algoritmos, y el 20 % restante (600 señales) se escondió para usarlo como conjunto de validación. Así nos aseguramos de evaluar cómo se comportan los modelos frente a datos que jamás han visto.

Pusimos a competir a dos modelos predictivos distintos:

- **Random Forest Regressor:** Este algoritmo funciona como un "consejo de sabios". Creamos 100 árboles de decisión diferentes que analizan la señal por separado y luego promedian sus respuestas. Tras darle los datos de prueba, obtuvo los siguientes errores:

- $RMSE_{\gamma} = 0.0165$
- $RMSE_k = 0.0988$

- **Red Neuronal (MLPRegressor):** Entrenamos un Perceptrón Multicapa con dos capas ocultas (de 128 y 64 neuronas) y activación no lineal ReLU. Tras ajustar sus pesos iterativamente, logró el siguiente desempeño en el examen final:

- $RMSE_{\gamma} = 0.0321$
- $RMSE_k = 0.0380$

Al mirar estos números, notamos dos cosas importantes. Primero, la red neuronal (MLP) logró un mejor desempeño general, lo cual tiene sentido ya que su arquitectura es mejor para capturar las relaciones en series de tiempo acopladas.

Segundo, vemos que el error al predecir γ es numéricamente distinto al error al predecir k . Esto no significa necesariamente que al modelo le cueste más predecir uno que el otro, sino que responden a escalas físicas y efectos distintos: γ domina la atenuación de la envolvente (que se ve muy afectada cuando la señal es tragada por el ruido), mientras que k gobierna la frecuencia, la cual deja una 'huella' en la señal.

d) El impacto del ruido experimental y el sobreajuste

Para poner a prueba la robustez de nuestros algoritmos, repetimos el proceso de entrenamiento completo, pero esta vez contaminando las señales con cinco niveles de ruido distintos ($\sigma = 0, 0,01, 0,02, 0,05, 0,10$). Al graficar cómo cambia el error de predicción en función de este ruido, el sistema nos revela dos lecciones muy importantes sobre la física del oscilador y el comportamiento de la Inteligencia Artificial:




Figura 2: Evolución del Error Cuadrático Medio (RMSE) en los conjuntos de entrenamiento (líneas punteadas) y validación (líneas continuas) a medida que aumenta la intensidad del ruido σ . Se evalúa por separado el error al inferir el roce γ (izquierda) y la rigidez k (derecha).

¿Qué parámetro es más difícil de inferir?

Si miramos ambos gráficos podemos observar que **inferir el roce γ es muchísimo más difícil que inferir la constante del resorte k** . Vemos que a medida que subimos el volumen del ruido, la curva de error para γ se dispara bruscamente, mientras que el error para k crece de forma mucho más controlada.

Físicamente, esto tiene todo el sentido del mundo. El parámetro k dicta la frecuencia, que es un patrón global, aunque la onda esté sucia con ruido, el algoritmo todavía puede contar los picos que sobresalen para estimar la frecuencia con buena precisión. Por el contrario, γ controla qué tan rápido se apaga la señal. Si la onda decae rápido y además hay mucho ruido, la señal queda escondida bajo las fluctuaciones aleatorias antes de llegar a la mitad del tiempo. En ese punto, la información del roce desaparece por completo.

Sobreajuste (*Overfitting*)

Si observamos sus líneas punteadas rojas (*Train*), vemos que se mantienen planas y pegadas a cero en todos los niveles de ruido. Esto significa que el algoritmo cree que está haciendo un buen trabajo al predecir los datos con los que estudió. Sin embargo, su línea continua roja (*Test*) se dispara hacia el cielo cuando le pasamos los datos del examen final.

¿Qué pasó aquí? El modelo cometió el error de **memorizar** el ruido. En vez de aprender la forma del oscilador armónico de fondo, el Random Forest se aprendió de memoria cada pequeño salto aleatorio del ruido en las señales de entrenamiento. Como el ruido en las señales de validación es completamente distinto (porque es aleatorio), todo ese patrón falso que el modelo memorizó hace que fracase en la prueba.

Problema 2: Terapia con protones y simulación Monte Carlo

a) Fundamentos físicos del transporte de protones en materia

1. El Pico de Bragg

La curva de dosis depositada $D(z)$ en función de la profundidad z describe cuánta energía deja el haz por cada gramo de masa que atraviesa. A diferencia de los fotones (rayos X) —cuya dosis cae de forma exponencial desde que entran al cuerpo—, los protones entran dejando una dosis relativamente baja y casi constante, hasta que de pronto depositan un máximo justo al final de su trayectoria. A este máximo lo llamamos el **Pico de Bragg**.

¿Por qué ocurre este peak al final? Por un efecto de tiempo de interacción. A medida que el protón avanza por el agua, va perdiendo energía y, por ende, frena. Mientras más lento va, más tiempo pasa cerca de los electrones de los átomos del medio en cada colisión, lo que aumenta su probabilidad de ionizarlos. Justo antes de detenerse por completo, su capacidad de arrancar electrones se vuelve máxima, depositando casi toda su energía cinética. Una vez que el protón se detiene, la dosis cae instantáneamente a cero.

2. Ecuación de Bethe-Bloch

La pérdida de energía promedio por unidad de longitud de una partícula cargada pesada está dada por la ecuación de Bethe-Bloch:

$$-\frac{dE}{dx} = Kz^2 \frac{Z}{A} \frac{1}{\beta^2} \left[\frac{1}{2} \ln \left(\frac{2m_e c^2 \beta^2 T_{\text{máx}}}{I^2} \right) - \beta^2 \right]$$

Identificación de los términos:

- K : Constante que agrupa factores fundamentales ($4\pi N_A r_e^2 m_e c^2$).
- z : Carga de la partícula incidente (para el protón, $z = 1$).
- Z, A : Número atómico y masa atómica del material absorbente.
- $\beta = v/c$: Velocidad relativa de la partícula incidente.
- $m_e c^2$: Energía en reposo del electrón (0,511 MeV).
- $T_{\text{máx}}$: Máxima energía cinética que el protón le puede transferir a un electrón libre en un choque frontal.
- I : Potencial medio de excitación del medio (≈ 75 eV para el agua). Físicamente, representa la energía promedio que cuesta excitar o arrancar un electrón de la molécula de agua.

Origen físico de los factores z^2 y $1/\beta^2$:

- **El factor z^2** : Proviene de la ley de Coulomb. La fuerza eléctrica que siente el electrón del medio es proporcional a la carga del protón ($F \propto z$). Como la energía transferida en el impulso mecánico es proporcional al cuadrado de la fuerza ($\Delta E \propto \int F^2 dt$), la carga queda elevada al cuadrado (z^2).
- **El factor $1/\beta^2$** : Representa el tiempo de interacción. Si el protón pasa a la velocidad de la luz ($\beta \rightarrow 1$), el tirón eléctrico que le da al electrón dura un instante fugaz. Si el protón va despacio ($\beta \ll 1$), pasa mucho tiempo "tirando" del electrón, por lo que le entrega muchísima más energía.



3. Energy Straggling

La ecuación de Bethe-Bloch es un *promedio determinista*, asume que el protón va perdiendo un porcentaje fijo de energía por cada milímetro. Sin embargo, a escala microscópica, el protón frena mediante miles de colisiones individuales y aleatorias contra electrones.

Como es un proceso estocástico, si lanzamos dos protones idénticos, uno podría chocar 1000 veces y el otro 1020 veces en el mismo tramo Δx . La aproximación de Bohr modela esta dispersión estadística como una campana de Gauss cuya varianza crece linealmente con la distancia recorrida:

$$\sigma_E^2 = 4\pi r_e^2 (m_e c^2)^2 N_e \frac{z^2}{\beta^2} \Delta x$$

Físicamente, el *straggling* hace que un haz monoenergético se vaya desinflando y ensanchando energéticamente a medida que entra en el agua.

4. Dispersión Coulombiana Múltiple

En el 99% de las colisiones, el protón choca con electrones, como el protón es ≈ 1836 veces más pesado, el electrón sale volando y el protón casi no se desvía de su trayectoria recta. Sin embargo, de vez en cuando el protón pasa muy cerca del núcleo de un átomo de oxígeno o hidrógeno.

Al ser una colisión contra una masa grande, el núcleo no se mueve, pero desvía al protón por repulsión. Tras acumular miles de estas pequeñas desviaciones angulares, el haz se va abriendo como un cono. La aproximación de Highland describe el ancho de esta distribución angular Gaussiana:

$$\theta_0 = \frac{13,6 \text{ MeV}}{\beta c p} z \sqrt{\frac{\Delta x}{X_0}} \left[1 + 0,038 \ln \left(\frac{\Delta x}{X_0} \right) \right]$$

donde p es el momentum del protón y X_0 es la *longitud de radiación* del material, un parámetro que mide qué tan denso nuclearmente es el medio para desviar partículas.

b) Implementación de Bethe-Bloch y cálculo del Rango CSDA

Evaluando la integral mediante la función `scipy.integrate.quad`, obtuvimos los siguientes rangos para el fantoma de agua y los contrastamos con la base de datos oficial PSTAR del NIST:

Energía Inicial (E_0)	Rango Bethe-Bloch (Nuestro)	Rango NIST PSTAR	Diferencia Porcentual
50 MeV	2.2331 cm	2,227 cm	0.27 %
150 MeV	15.9641 cm	15,77 cm	1.23 %
250 MeV	38.6519 cm	37,90 cm	1.98 %

Tabla 1: Comparación entre el rango CSDA calculado por integración numérica de Bethe-Bloch y los valores tabulados por el NIST para agua líquida.

Análisis de la comparación

Nuestros resultados numéricos coinciden con los datos de referencia, observando la buena relación no lineal entre el alcance y la energía.

La pequeña diferencia porcentual observada (en torno al 1 %) se puede justificar, dado que la ecuación de Bethe-Bloch es el modelo teórico. En contraste, las tablas del NIST incorporan dos términos de corrección de orden superior.

c) Simulación del transporte determinista y Pico de Bragg

Los resultados de esta simulación idealizada se presentan en la curva negra punteada de la Figura 3:




Figura 3: Curvas de dosis depositada $D(z)$ en agua para un haz de 10^4 protones de 150 MeV. La línea negra segmentada muestra el modelo determinista puro (CSDA), mientras que la curva roja continua ilustra la simulación Monte Carlo incorporando el straggling energético.

Al analizar la curva, observamos que la forma del Pico de Bragg: el haz entra al agua depositando una dosis baja y bastante plana, y justo al final de su recorrido, la dosis se dispara hacia arriba formando una aguja infinitamente delgada.

Al verificar la posición de este peak en nuestro gráfico, comprobamos que **coincide exactamente con el valor del rango $R_{CSDA} \approx 15,77$ cm calculado en el inciso anterior.**

d) Incorporación de *straggling*

Al comparar la curva roja estocástica con la aguja negra (determinista) en la Figura 3, notamos tres grandes diferencias:

1. **Reducción de la dosis máxima:** El peak rojo es visiblemente más bajo que el determinista. Como los protones ya no se detienen todos en el mismo milímetro exacto, la energía total se reparte en un volumen mayor.



2. **Ensanchamiento de la curva:** El pico adquiere una forma redondeada y una anchura medible. Al calcular la desviación estándar de las posiciones de detención de los protones, obtuvimos un ensanchamiento espacial de:

$$\sigma_R = 0.2917 \text{ cm}$$

3. **Penetración distal:** En el modelo determinista, más allá de 15,77 cm la dosis es estrictamente cero. En el modelo con *straggling*, existe una cola de protones que, por azar, sufrieron menos colisiones de lo normal y lograron penetrar un par de milímetros más profundo antes de frenar.

Relevancia clínica del ensanchamiento (σ_R)

Para la física médica y la oncología, conocer y medir este ensanchamiento σ_R es muy importante por dos factores fundamentales:

- **Márgenes de seguridad distal:** Confiarse de la curva determinista pondría en riesgo a los órganos cercanos tras el tumor debido a la "cola distal" del *straggling*. Medir σ_R permite trazar un margen de seguridad para garantizar que la dosis caiga a cero antes de irradiar tejido sano vital.
- **Construcción del SOBP (*Spread-Out Bragg Peak*):** Para irradiar tumores tridimensionales se superponen haces de distintas energías. Conocer σ_R permite calcular el peso exacto de cada pico para que su suma genere una superficie de dosis uniforme sobre todo el volumen objetivo.